

# 关联分析

## Association Analysis

孟庆鑫

人工智能学院



唐山学院  
TANGSHAN UNIVERSITY

# 课件获取地址



GitHub



Gitee

1. 核心度量：我们如何衡量“关联”？
2. 进阶讨论：局限性与现代方法
3. 统计陷阱：辛普森悖论
4. 深度思考：从关联分析走向概率建模

在许多实际问题中，我们面对的数据形式是：

$$\mathcal{D} = \{T_1, T_2, \dots, T_N\},$$

其中每个  $T_i$  是一次事件记录，例如：

- 一次购物篮中的商品集合
- 一次网页访问中的点击页面集合
- 一次诊疗过程中的症状与用药集合

我们需要发现数据  $\mathcal{D}$  中的共现结构，即

- 哪些事件经常一起发生？
- 是否存在稳定、可重复的组合模式？

# 从一份交易数据开始

| 交易编号 | $T_1$ | $T_2$ | $T_3$ | $T_4$ | $T_5$ | $T_6$ | $T_7$ | $T_8$ | $T_9$ | $T_{10}$ |
|------|-------|-------|-------|-------|-------|-------|-------|-------|-------|----------|
| 购买商品 | A     | A     | A     |       | A     | A     |       | A     |       | A        |
|      | B     | B     |       | B     | B     |       | B     | B     |       | B        |
|      | C     |       | C     | C     | C     |       |       |       | C     |          |
|      |       |       |       |       |       | D     | D     | D     |       |          |

其中 A: 面包 B: 牛奶 C: 鸡蛋 D: 啤酒

问: 哪些商品经常一起被买?

- A 和 B?
- B 和 C?
- A、B、C?

# 第一步：单个商品出现了多少次？

| 交易编号 | $T_1$ | $T_2$ | $T_3$ | $T_4$ | $T_5$ | $T_6$ | $T_7$ | $T_8$ | $T_9$ | $T_{10}$ |
|------|-------|-------|-------|-------|-------|-------|-------|-------|-------|----------|
| 购买商品 | A     | A     | A     |       | A     | A     |       | A     |       | A        |
|      | B     | B     |       | B     | B     |       | B     | B     |       | B        |
|      | C     |       | C     | C     | C     |       |       |       | C     |          |
|      |       |       |       |       |       | D     | D     | D     |       |          |

| 商品   | A | B | C | D |
|------|---|---|---|---|
| 出现次数 | 7 | 7 | 5 | 3 |

共有 10 笔交易

# 我们需要一个“标准化”的频率

定义（支持度 support）

$$\text{support}(X) = \frac{\text{包含 } X \text{ 的交易数}}{\text{总交易数}}$$

例如：

$$\begin{aligned} \text{support}(A) &= \frac{7}{10} & \text{support}(B) &= \frac{7}{10} \\ \text{support}(C) &= \frac{5}{10} & \text{support}(D) &= \frac{3}{10} \end{aligned}$$

当交易数量很大时， $\text{support}(X)$  可看作真实概率的经验估计。

# 频繁项的直觉筛选

## 问题

如果一个商品只出现了很少次，它值得分析吗？

例如设定最小支持度：

$$\text{minsupp} = 40\%$$

- $A, B, C$  保留
- $D$  被淘汰

## 第二步：两个商品一起出现了多少次？

| 交易编号 | $T_1$ | $T_2$ | $T_3$ | $T_4$ | $T_5$ | $T_6$ | $T_7$ | $T_8$ | $T_9$ | $T_{10}$ |
|------|-------|-------|-------|-------|-------|-------|-------|-------|-------|----------|
| 购买商品 | A     | A     | A     |       | A     | A     |       | A     |       | A        |
|      | B     | B     |       | B     | B     |       | B     | B     |       | B        |
|      | C     |       | C     | C     | C     |       |       |       | C     |          |
|      |       |       |       |       |       | D     | D     | D     |       |          |

| 商品组合 | $A, B$ | $A, C$ | $B, C$ |
|------|--------|--------|--------|
| 出现次数 | 5      | 3      | 3      |

对应支持度：

$$\text{support}(A, B) = \frac{5}{10} \quad \text{support}(A, C) = \frac{3}{10} \quad \text{support}(B, C) = \frac{3}{10}$$

# 一个重要性质

## 性质

$$\text{support}(A, B) \leq \min \{ \text{support}(A), \text{support}(B) \}$$

为什么？

- 每一次出现 AB，一定也出现 A（一定也出现 B）
- 因此组合只会更稀有

## 第三步：统计三个商品一起出现了多少次

由于

- $\text{support}(A, C) = 0.3$ ,  $A, C$  组合被淘汰
- $\text{support}(B, C) = 0.3$ ,  $B, C$  组合被淘汰

这导致

$$\begin{aligned}\text{support}(A, B, C) &\leq \min\{\text{support}(A, C), \text{support}(B, C), \dots\} \\ &\leq \text{minsupp}\end{aligned}$$

因此，统计三个商品一起出现了多少次已无必要

# Apriori 原理

## Apriori 原理

如果一个项集不是频繁的，那么任何包含它的更大项集都不可能是频繁的。

Apriori 能减少计算：

- 不需要枚举所有组合，依据 minsupp 做剪枝
- 先找频繁 1-项集
- 再由它们生成候选 2-项集
- 不断向上扩展

# 理解最小支持度 minsupp

假设共有  $m$  种商品。每个商品要么购买，要么不购买。

所有可能商品组合数量级为  $2^m$ ，例如：

| 商品数 | 可能组合数量级   |
|-----|-----------|
| 10  | $10^3$    |
| 20  | $10^6$    |
| 50  | $10^{15}$ |

绝大多数商品组合在数据中出现极少甚至从未出现。

因此关联分析引入最小支持度： $\text{support}(X) \geq \text{minsupp}$

只保留出现频率足够高的商品组合。

Apriori 算法利用这一条件进行大规模剪枝，从而大幅减少计算量。

# 从组合到规则

## 问题

在买了 A 的交易中，有多少比例也买了 B?

## 定义 ( 置信度 confidence )

$$\text{confidence}(A \rightarrow B) = \frac{\text{support}(A, B)}{\text{support}(A)}$$

例如：

$$\text{confidence}(A \rightarrow B) = \frac{5}{7}$$

# 关联规则的概率解释

关联规则

$$X \rightarrow Y$$

其置信度为

$$\text{confidence}(X \rightarrow Y) = \frac{\text{support}(X, Y)}{\text{support}(X)}$$

实际上是经验条件概率

$$\hat{P}(Y | X)$$

# 为什么仅有 Confidence 还不够?

如果商品  $B$  本身非常常见,

$$\text{support}(B) \approx 1$$

那么即使

$$\text{confidence}(A \rightarrow B)$$

很高, 也未必说明  $A$  与  $B$  真的有关联。

因此需要新的度量

# 提升度 Lift

## 定义

$$\text{lift}(A, B) = \frac{\text{support}(A, B)}{\text{support}(A) \text{support}(B)}$$

解释：

- $= 1$  : 独立
- $> 1$  : 正相关
- $< 1$  : 负相关

Lift 衡量的是共现概率相对于独立情况的放大倍数

# Lift 示例

| 交易编号 | $T_1$ | $T_2$ | $T_3$ | $T_4$ | $T_5$ | $T_6$ | $T_7$ | $T_8$ | $T_9$ | $T_{10}$ |
|------|-------|-------|-------|-------|-------|-------|-------|-------|-------|----------|
| 购买商品 | A     | A     | A     |       | A     | A     |       | A     |       | A        |
|      | B     | B     |       | B     | B     |       | B     | B     |       | B        |
|      | C     |       | C     | C     | C     |       |       |       | C     |          |
|      |       |       |       |       |       | D     | D     | D     |       |          |

$$\text{confidence}(A \rightarrow B) = \frac{5}{7} \quad \text{lift}(A, B) = \frac{0.5}{0.7 \times 0.7} \approx 1.02 > 1$$

$$\text{confidence}(A \rightarrow C) = \frac{3}{7} \quad \text{lift}(A, C) = \frac{0.3}{0.7 \times 0.5} \approx 0.857 < 1$$

尽管  $\text{confidence}(A \rightarrow B)$  较高,  $A$  与  $B$  几乎独立

1. 核心度量：我们如何衡量“关联”？
2. 进阶讨论：局限性与现代方法
3. 统计陷阱：辛普森悖论
4. 深度思考：从关联分析走向概率建模

# 回顾 Apriori

## Apriori 算法流程:

- 扫描数据库，计算所有 1-项集的支持度，剔除低于 minsupp 的，得到  $L_1$
- 连接步：由  $L_k$  自身连接生成候选  $(k + 1)$ -项集  $C_{k+1}$
- 剪枝步：检查  $C_{k+1}$  的子集是否在  $L_k$  中，若不在则删除
- 再次扫描数据库计算  $C_{k+1}$  的支持度，剔除低于 minsupp 的，得到  $L_{k+1}$
- 重复直至无法生成新的频繁项集

# Apriori 的局限性

尽管 Apriori 实现了剪枝，但它仍然存在两个致命缺陷：

- 多次扫描数据库：每增加一阶项集都要遍历一次全量数据
- 候选集数量依然可能很大

# FP-Growth 算法：不产生候选集的搜索

核心思想：

- 将数据库压缩进一棵树，FP-Tree ( Frequent Pattern Tree )
- 通过分治法挖掘条件数据库

优势：

- 只扫描数据库 2 次
- 避免了生成数以百万计的候选集

# 为什么要发明 FP-Growth?

- Apriori 的问题：逐层搜索

每次计算都要扫描整个数据库，且会产生海量的候选组合。

- FP-Growth 的核心：全局压缩

只扫描 2 次数据库，通过 FP-Tree 把整张交易表压缩进一棵树里。

# 第一步：构建项头表（Header Table）

先扫描一遍数据库，算出每个商品的出现次数，并从高到低排序：

|          |   |
|----------|---|
| <i>A</i> | 7 |
| <i>B</i> | 7 |
| <i>C</i> | 5 |
| <i>D</i> | 3 |

确定 FP-Tree 插入的顺序： $A \longrightarrow B \longrightarrow C \longrightarrow D$


## 第二步：逐条插入，构建 FP-Tree

从一个空的 Root 节点开始，把排序后的项集一条条“喂”给这棵树




## 第二步：逐条插入，构建 FP-Tree

按照  $A \longrightarrow B \longrightarrow C \longrightarrow D$  的次序插入  $T_1 = \{A, B, C\}$




## 第二步：逐条插入，构建 FP-Tree

按照  $A \longrightarrow B \longrightarrow C \longrightarrow D$  的次序插入  $T_2 = \{A, B\}$




## 第二步：逐条插入，构建 FP-Tree

按照  $A \longrightarrow B \longrightarrow C \longrightarrow D$  的次序插入  $T_3 = \{A, C\}$




## 第二步：逐条插入，构建 FP-Tree

按照  $A \longrightarrow B \longrightarrow C \longrightarrow D$  的次序插入  $T_4 = \{B, C\}$




## 第二步：逐条插入，构建 FP-Tree

按照  $A \longrightarrow B \longrightarrow C \longrightarrow D$  的次序插入  $T_5 = \{A, B, C\}$




## 第二步：逐条插入，构建 FP-Tree

按照  $A \longrightarrow B \longrightarrow C \longrightarrow D$  的次序插入  $T_6 = \{A, D\}$




## 第二步：逐条插入，构建 FP-Tree

按照  $A \longrightarrow B \longrightarrow C \longrightarrow D$  的次序插入  $T_7 = \{B, D\}$




## 第二步：逐条插入，构建 FP-Tree

按照  $A \longrightarrow B \longrightarrow C \longrightarrow D$  的次序插入  $T_8 = \{A, B, D\}$




## 第二步：逐条插入，构建 FP-Tree

按照  $A \rightarrow B \rightarrow C \rightarrow D$  的次序插入  $T_9 = \{C\}$




## 第二步：逐条插入，构建 FP-Tree

按照  $A \longrightarrow B \longrightarrow C \longrightarrow D$  的次序插入  $T_{10} = \{A, B\}$



# FP-Tree 构建结果



参考：FP-Tree 的动态构建过程

## 第三步：怎么“挖”？（以 D 为例）

构建完树后，我们要找跟  $D$  相关的频繁模式。

这时候不需要再看原始数据，只看树：

- ① 在树中找到  $D$  的所有位置：
- ② 提取“路径前缀”（条件模式基，Conditional Pattern Base）：
  - 从  $T_6$  来的  $D$ ：前缀是  $\{A\}$ ，计数 1
  - 从  $T_7$  来的  $D$ ：前缀是  $\{B\}$ ，计数 1
  - 从  $T_8$  来的  $D$ ：前缀是  $\{A, B\}$ ，计数 1
- ③ 在  $D$  的“小世界”里统计：
  - $A$  出现了 2 次， $B$  出现了 2 次
  - 如果我们设定  $\text{minsupp} = 2$ ，那么我们发现：  
 $\{A, D\}$  是频繁的， $\{B, D\}$  也是频繁的。

# FP-Growth 背后的本质

- 压缩：FP-Tree 就是把数据库里重复出现的组合合并了
- 排序：高频的商品排在前面能让更多的交易共享同一段树干，压缩率最高
- 挖掘：挖掘过程就像是“顺瓜摸藤”。先找到瓜（项头表里的尾项），然后沿着藤（树路径）往回找

# Apriori vs. FP-Growth

|      | Apriori     | FP-Growth   |
|------|-------------|-------------|
| 核心思想 | 基于候选集的连接与剪枝 | 基于树结构的递归挖掘  |
| 扫描次数 | 跟随项集大小      | 固定 2 次      |
| 内存占用 | 较低（每次只处理一层） | 较高（整棵树存入内存） |
| 适用场景 | 简单、数据集较小时   | 大规模、稠密数据集   |

1. 核心度量：我们如何衡量“关联”？
2. 进阶讨论：局限性与现代方法
3. 统计陷阱：辛普森悖论
4. 深度思考：从关联分析走向概率建模

# 药效挖掘中的“神规则”

我们在医疗日志中挖掘规则：

服药 → 康复

| 分组  | 康复人数 / 总人数 | 康复率   |
|-----|------------|-------|
| 服药组 | 273 / 506  | 54.0% |
| 对照组 | 289 / 771  | 37.5% |

$\text{confidence}(\text{服药} \rightarrow \text{康复}) \approx 0.54$

$\text{lift}(\text{服药} \rightarrow \text{康复}) \approx 1.23$

从指标上看，这是一个“强关联”规则

# 真相：被“性别”掩盖的事实

| 性别  | 服药组               | 对照组               |
|-----|-------------------|-------------------|
| 男性  | 81 / 263 (30.8%)  | 234 / 703 (33.3%) |
| 女性  | 192 / 243 (79.0%) | 55 / 68 (80.9%)   |
| 全人群 | 273 / 506 (54.0%) | 289 / 771 (37.5%) |

男性： 服药组 ( 30.8% ) < 对照组 ( 33.3% )    lift  $\approx$  0.94

女性： 服药组 ( 79.0% ) < 对照组 ( 80.9% )    lift  $\approx$  0.99

**结论：在两个子群体中，服药表现都比不服药差**

# 为什么指标会“骗人”？

## 辛普森悖论（Simpson's Paradox）的底层逻辑

在这份数据中，存在一个隐藏的**混杂变量**：性别

- 女性有着更高的自愈率
- 分配权重偏差：
  - 女性（自愈率高）里有 78% 的人服了药
  - 男性（自愈率低）里只有 27% 的人服了药
- 药物在全人群的“高 Lift”其实是蹭了“女性高自愈率”的光

# 给数据挖掘者的启示

## 启示：

不要盲目相信自动化算法产出的强关联规则，  
在涉及决策（如医疗、金融）时，  
必须进行数据分层验证，排除混杂变量的干扰

# 关联不代表因果

关联分析只发现统计相关性，不蕴含因果关系。

经典例子：冰淇淋销量上升 与 溺水事故上升 存在关联。

真正原因是 夏天高温

- 关联分析无法区分相关性与因果性
- 现代数据科学越来越重视因果推断

1. 核心度量：我们如何衡量“关联”？
2. 进阶讨论：局限性与现代方法
3. 统计陷阱：辛普森悖论
4. 深度思考：从关联分析走向概率建模

# 既然算法会骗人，那关联分析有什么用？

在最初的例子中，我们计算了：

- 商品组合出现的频率（组合概率）
- 在买了 A 的交易中，有多少比例也买了 B（条件概率）

例如：

$$\text{support}(A, B) = 0.5 \quad \text{confidence}(A \rightarrow B) = \frac{5}{7}$$

那么问题来了：关联分析究竟在建模什么？

# 关联分析的本质

关联分析并没有建立完整概率模型。它做的是：

## 核心思想

从数据中提取稳定出现的经验概率约束

例如：

$$\hat{P}(A) = \text{support}(A) = 0.7$$

$$\hat{P}(A, B) = \text{support}(A, B) = 0.5$$

这些经验概率都是经过 minsupp 剪枝后保留下来的

# 概率约束

这些支持度实际上是经验事实：

- 某些商品组合经常一起出现

例如：

$$\hat{P}(A, B) = 0.5$$

意味着 50% 的交易同时购买了  $A$  和  $B$

# 这些约束能确定完整概率吗？

答案是：

**通常不能**

这些约束不足以唯一确定概率分布。

原因：

- 在理论上，如果统计所有商品组合的支持度，我们可以得到完整的经验概率分布
- 但在真实的大规模数据中，组合数量级呈指数增长，因此 Apriori 通过 minsupp 剪枝，只保留高频组合
- 结果是我们只得到部分概率约束，而不是完整概率模型

# 从关联分析到概率建模

既然存在很多满足这些约束的概率分布，那么：

## 问题

应该选择哪一个概率分布？

一种重要思想是 **最大熵原理**：

**在满足约束的前提下，选择熵最大的概率分布**

# 关联分析的现实地位

关联规则不再是工业界的核心算法  
但它的思想仍然存在

# 课程小结

- 三个度量：Support、Confidence、Lift
- 算法的进化：Apriori 暴力枚举 → FP-Growth 结构压缩
- 批判性思维：我们看到的“关联”，究竟是真实的规律，还是混杂变量投射下的幻像？
- 真正的洞察，来自于你对数据背后“因果”的敬畏

# 课程小结

感谢倾听，保持对数据的审慎与好奇！