

聚类分析

Clustering Analysis

孟庆鑫

人工智能学院



唐山学院
TANGSHAN UNIVERSITY

课件获取地址



GitHub



Gitee

我们一直以为
数据中存在“结构”
但也许……
结构不是被发现的
而是被定义的

一个现实问题：通讯基站的布局

已知：城市中有 n 个信号接收终端 $x_1, x_2, \dots, x_n$

需求：部署 k 个基站 $\mu_1, \mu_2, \dots, \mu_k$

问题：我们该如何选择这些基站的位置？

一些直观的想法

- 将基站均匀分布在城市中？
- 将基站放在终端密集区域？
- 随机选取若干位置？

一些直观的想法

- 将基站均匀分布在城市中？
- 将基站放在终端密集区域？
- 随机选取若干位置？

这些方法真的合理吗？

问题的本质困难

- 基站的位置会影响终端如何连接

问题的本质困难

- 基站的位置会影响终端如何连接
- 终端的连接方式又会影响基站应放在哪里

问题的本质困难

- 基站的位置会影响终端如何连接
- 终端的连接方式又会影响基站应放在哪里

这是一个相互依赖的问题

引入物理规律，设定合理目标

- 每个终端连接最近的基站
- 信号传播存在路径损耗
- 损耗与距离的平方成正比
- 为保证终端的接收功率达标，基站为每个终端独立分配的发射功率必须补偿损耗

引入物理规律，设定合理目标

- 每个终端连接最近的基站
- 信号传播存在路径损耗
- 损耗与距离的平方成正比
- 为保证终端的接收功率达标，基站为每个终端独立分配的发射功率必须补偿损耗

目标：最小化总发射功率

思考：如果把终端的功率也计入优化目标，问题会发生本质变化吗？

问题形式化

假设 x_i 连接基站 $\mu_{c(i)}$ ，则：

- 发射功率：

$$P_i \propto \|x_i - \mu_{c(i)}\|^2$$

问题形式化

假设 x_i 连接基站 $\mu_{c(i)}$ ，则：

- 发射功率：

$$P_i \propto \|x_i - \mu_{c(i)}\|^2$$

- 总功率：

$$P \propto \sum_{i=1}^n \|x_i - \mu_{c(i)}\|^2$$

问题形式化

假设 x_i 连接基站 $\mu_{c(i)}$ ，则：

- 发射功率：

$$P_i \propto \|x_i - \mu_{c(i)}\|^2$$

- 总功率：

$$P \propto \sum_{i=1}^n \|x_i - \mu_{c(i)}\|^2$$

- 最近连接原则：

$$c(i) = \arg \min_j \|x_i - \mu_j\|$$

总功率的等价表示

$$P \propto \sum_{i=1}^n \|x_i - \mu_{c(i)}\|^2 = \sum_{j=1}^k \sum_{i:c(i)=j} \|x_i - \mu_j\|^2$$

why?

总功率的等价表示

$$P \propto \sum_{i=1}^n \|x_i - \mu_{c(i)}\|^2 = \sum_{j=1}^k \sum_{i:c(i)=j} \|x_i - \mu_j\|^2 \quad \text{why?}$$

```
P = 0      # P: total power
for i in n:
    j = c(i)    # nearest station index
    P += dist(x_i, mu_j)**2
```


总功率的等价表示

$$P \propto \sum_{i=1}^n \|x_i - \mu_{c(i)}\|^2 = \sum_{j=1}^k \sum_{i:c(i)=j} \|x_i - \mu_j\|^2 \quad \text{why?}$$

```
P = 0      # P: total power
for i in n:
    j = c(i)    # nearest station index
    P += dist(x_i, mu_j)**2
```

```
P = 0      # P: total power
for j in k:
    for i in n:
        if connect(i, j):
            P += dist(x_i, mu_j)**2
```

如何减少总功率？

总功率

$$P = \sum_{j=1}^k \sum_{i:c(i)=j} \|x_i - \mu_j\|^2$$

减少 P 等价于减少

$$\sum_{i:c(i)=j} \|x_i - \mu_j\|^2$$

如何减少总功率？

总功率

$$P = \sum_{j=1}^k \sum_{i:c(i)=j} \|x_i - \mu_j\|^2$$

减少 P 等价于减少

$$\sum_{i:c(i)=j} \|x_i - \mu_j\|^2$$

即：每个基站对应的部分功率

最优位置在哪里？

考虑终端分配固定

对于基站 μ_j :

$$\min_{\mu_j} \sum_{i: c(i)=j} \|x_i - \mu_j\|^2$$

最优位置在哪里？

考虑终端分配固定

对于基站 μ_j :

$$\min_{\mu_j} \sum_{i:c(i)=j} \|x_i - \mu_j\|^2$$

对 μ_j 求导:

$$\mu_j = \frac{1}{\text{card}\{i : c(i) = j\}} \sum_{i:c(i)=j} x_i$$

最优位置在哪里？

考虑终端分配固定

对于基站 μ_j :


$$\min_{\mu_j} \sum_{i: c(i)=j} \|x_i - \mu_j\|^2$$

对 μ_j 求导:

$$\mu_j = \frac{1}{\text{card}\{i : c(i) = j\}} \sum_{i: c(i)=j} x_i$$

基站应位于所有连接终端的 **几何中心**

基站布局示意图



问题怎么解？

- 基站位置未知
- 终端分配未知

问题怎么解？

- 基站位置未知
- 终端分配未知

我们能否把问题拆开？

关键观察

- 如果基站位置固定:

$$c(i) = \arg \min_j \|x_i - \mu_j\|$$

关键观察

- 如果基站位置固定:

$$c(i) = \arg \min_j \|x_i - \mu_j\|$$

- 如果终端分配固定:

$\mu_j =$ 所有连接 μ_j 的终端的几何中心

关键观察

- 如果基站位置固定：

$$c(i) = \arg \min_j \|x_i - \mu_j\|$$

- 如果终端分配固定：

$\mu_j =$ 所有连接 μ_j 的终端的几何中心

那我们为什么不交替进行这两步？

一个自然的算法

- 初始化基站位置 $\mu_1, \dots, \mu_k$

- 重复以下步骤：

分配：每个终端连接最近的基站

更新：将基站移动到对应的几何中心

一个自然的算法

- 初始化基站位置 $\mu_1, \dots, \mu_k$

- 重复以下步骤：

分配：每个终端连接最近的基站

更新：将基站移动到对应的几何中心

这就是 K-means 算法

k-means 是否会陷入死循环？

我们在不断地：

分配 $\longrightarrow$ 更新 $\longrightarrow$ 分配 $\longrightarrow$ 更新 $\longrightarrow \dots$

这些操作是否可能来回反复？

重要观察

我们其实一直在优化同一个目标函数：

$$P \propto \sum_{i=1}^n \|x_i - \mu_{c(i)}\|^2 = \sum_{j=1}^k \sum_{i:c(i)=j} \|x_i - \mu_j\|^2$$

重要观察

我们其实一直在优化同一个目标函数：

$$P \propto \sum_{i=1}^n \|x_i - \mu_{c(i)}\|^2 = \sum_{j=1}^k \sum_{i:c(i)=j} \|x_i - \mu_j\|^2$$

每一步都不会增加总功率（通常会严格下降）：

- 分配：每个终端选择最近的基站，不会增加总距离，即不会增加总功率
- 更新：几何中心最小化每个基站的功率，也不会增加总功率

结论：k-means 会在有限步内收敛

- 每一步都使 P 不增加（通常严格下降）
- $P \geq 0$ （有下界）
- 所有可能的“分配方式”是有限的（最多 k^n 种分配）

结论：k-means 会在有限步内收敛

- 每一步都使 P 不增加（通常严格下降）
- $P \geq 0$ （有下界）
- 所有可能的“分配方式”是有限的（最多 k^n 种分配）

K-means 不会陷入死循环
它一定在有限步内收敛

结论：k-means 会在有限步内收敛

- 每一步都使 P 不增加（通常严格下降）
- $P \geq 0$ （有下界）
- 所有可能的“分配方式”是有限的（最多 k^n 种分配）

K-means 不会陷入死循环

它一定在有限步内收敛

但… 它不一定找到“最优解”

最优位置一定是几何中心么？

基站的最优位置为什么是几何中心？

最优位置一定是几何中心么？

基站的最优位置为什么是几何中心？

这是最小化“平方距离”的必然

最优位置一定是几何中心么？

基站的最优位置为什么是几何中心？

这是最小化“平方距离”的必然

如果损耗与距离成正比，而不是距离的平方呢？

新的模型：配送问题

- 每个终端需要配送服务
- 配送成本与距离成正比

目标变为最小化总成本 C ：

$$C \propto \sum_{i=1}^n \|x_i - \mu_{c(i)}\| = \sum_{j=1}^k \sum_{i: c(i)=j} \|x_i - \mu_j\|$$

引入合理假设

- 城市道路是横平竖直的
- 配送只能沿街道走

此时的距离度量又被称为 Manhattan 距离：

$$\|x_i - \mu_j\| = |x_i^1 - \mu_j^1| + |x_i^2 - \mu_j^2|$$

最优位置还一样吗？

对于基站 μ_j ：

$$\begin{aligned} & \min_{\mu_j} \sum_{i:c(i)=j} \|x_i - \mu_j\| \\ &= \min_{\mu_j^1} \sum_{i:c(i)=j} |x_i^1 - \mu_j^1| + \min_{\mu_j^2} \sum_{i:c(i)=j} |x_i^2 - \mu_j^2| \end{aligned}$$

解得：

μ_j^1 = 水平方向的坐标中位数

μ_j^2 = 竖直方向的坐标中位数

最优位置还一样吗？

对于基站 μ_j ：

$$\begin{aligned} & \min_{\mu_j} \sum_{i:c(i)=j} \|x_i - \mu_j\| \\ &= \min_{\mu_j^1} \sum_{i:c(i)=j} |x_i^1 - \mu_j^1| + \min_{\mu_j^2} \sum_{i:c(i)=j} |x_i^2 - \mu_j^2| \end{aligned}$$

解得：

μ_j^1 = 水平方向的坐标中位数

μ_j^2 = 竖直方向的坐标中位数

基站应位于所有连接终端的 **坐标中位数**

相应的算法

- 初始化基站位置 $\mu_1, \dots, \mu_k$

- 重复以下步骤：

分配：每个终端连接最近的基站

更新：将基站移动到对应的坐标中位数

相应的算法

- 初始化基站位置 $\mu_1, \dots, \mu_k$

- 重复以下步骤：

分配：每个终端连接最近的基站

更新：将基站移动到对应的坐标中位数

这就是 K-medians 算法

K-means vs. K-medians

- 我们都在用 k 个“中心”来解释数据
- K-means 的“中心”是几何中心
- K-medians 的“中心”是坐标中位数

K-means vs. K-medians

- 我们都在用 k 个“中心”来解释数据
- K-means 的“中心”是几何中心
- K-medians 的“中心”是坐标中位数

所谓“中心”，不是数据决定的
是我们定义的损失函数决定的

不论 K-means 还是 K-medians
它们都要求我们在一开始就回答一个问题：
 k 是多少？

我们真的知道有几类吗？

将一个城市划分为若干区域：

- $k = 2$ ：东西两区
- $k = 5$ ：五个行政区划
- $k = 20$ ：社区划分

我们真的知道有几类吗？

将一个城市划分为若干区域：

- $k = 2$ ：东西两区
- $k = 5$ ：五个行政区划
- $k = 20$ ：社区划分

这些划分，哪个是“正确”的？

答案是：它们都正确
只是处在不同的“尺度”上

问题的转变

我们不应该问 k 是多少

而应该问：

数据在不同尺度下是如何组织的？

一种新的思路

- 不预先指定 k
- 从最细粒度开始（每个点一个类）
- 逐步合并“最接近”的两个类
- 最终得到一棵层次结构树（dendrogram）

具体要如何合并？

我们说：不断合并“最接近”的两个类
可是……

类与类之间的距离，如何定义？

具体要如何合并？

我们说：不断合并“最接近”的两个类

可是……

类与类之间的距离，如何定义？

这一步，没有唯一答案

不同的距离定义代表不同的“结构假设”

最近距离 (Single Linkage)

$$d(A, B) = \min_{x \in A, y \in B} \|x - y\|$$

直觉：只要两个类之间“有一点靠得很近”，就合并



最远距离 (Complete Linkage)

$$d(A, B) = \max_{x \in A, y \in B} \|x - y\|$$


直觉：两个类只有在“整体都很接近”时才合并



平均距离 (Average Linkage)

$$d(A, B) = \frac{1}{|A||B|} \sum_{x \in A} \sum_{y \in B} \|x - y\|$$

直觉：看整体平均关系，在“局部连接”和“整体紧凑”之间折中



不同的距离意味着什么？

- Single Linkage: 强调“连通性”
- Complete Linkage: 强调“紧致性”
- Average Linkage: 强调“整体相似性”

不同的距离意味着什么？

- Single Linkage: 强调“连通性”
- Complete Linkage: 强调“紧致性”
- Average Linkage: 强调“整体相似性”

不同的距离选择隐含着
你如何“定义类”

层次聚类如何生成这棵树？

算法过程：

- 初始：每个点单独作为一个类
- 计算所有类之间的距离
- 找到距离最小的两个类并合并
- 更新类之间距离
- 重复上述过程


层次聚类如何生成这棵树？

算法过程：

- 初始：每个点单独作为一个类
- 计算所有类之间的距离
- 找到距离最小的两个类并合并
- 更新类之间距离
- 重复上述过程

每一次合并都会在树上产生一个新的节点

层次结构的可视化：Dendrogram



如何理解这棵树？

- 越早合并 → 两个类越接近
- 越晚合并 → 两个类差异越大
- 高度 → 不相似程度
- “横切一刀”，切得高 → 类少（ k 小）
- “横切一刀”，切得低 → 类多（ k 大）

层次聚类在做什么

层次聚类展示了

数据在不同尺度下是如何组织的

不同的聚类数 k

暗含我们在哪个尺度上观察数据

整理逻辑链条

到目前为止，我们经历了如下的逻辑链条：

- 我们假设数据可以用 k 个“中心”来解释
- “中心”可以是几何中心，也可以是坐标中位数
- k 暗含我们在哪个尺度上观察数据


整理逻辑链条

到目前为止，我们经历了如下的逻辑链条：


- 我们假设数据可以用 k 个“中心”来解释
- “中心”可以是几何中心，也可以是坐标中位数
- k 暗含我们在哪个尺度上观察数据

质疑：中心化假设一定正确么？

挑战中心化假设



K-means 的崩塌



失败的原因

K-means 失败的原因

是因为它假设

每个类都有一个中心

从“中心世界”走向“密度世界”

如果类没有中心

那它是如何存在的？

从“中心世界”走向“密度世界”

如果类没有中心

那它是如何存在的？

也许

密集的地方自然形成一类

从一个点出发

任意选择一个数据点

我们看它周围是否有足够多的邻居

从一个点出发

任意选择一个数据点

我们看它周围是否有足够多的邻居

- 画一个半径为 ε 的邻域
- 数一数邻域中的点数
- 若点数 $\geq \text{MinPts}$ ，则该点有足够多的邻居

让一个类“生长”出来

如果这个点有足够多的邻居
我们就把它作为起点开始向外扩展
把它的所有邻居全部纳入同一类

继续扩展

新加入的邻居点，是否也可以继续扩展？

继续扩展

新加入的邻居点，是否也可以继续扩展？

如果它周围也有足够多的邻居

那么它也可以继续向外扩展

继续扩展

新加入的邻居点，是否也可以继续扩展？

如果它周围也有足够多的邻居

那么它也可以继续向外扩展

于是，一个类开始不断“长大”

什么时候停止？

当没有新的点可以继续扩展时，这个类就形成了

什么时候停止？

当没有新的点可以继续扩展时，这个类就形成了

然后我们换一个尚未处理的点

重复这个过程

并不是所有点都能形成类

有些点周围没有足够的邻居

它们既无法启动一个新类

也无法被纳入某个已有类

并不是所有点都能形成类

有些点周围没有足够的邻居

它们既无法启动一个新类

也无法被纳入某个已有类

这些点被称为**噪声**

上述过程被称为 DBSCAN 算法

Density-Based Spatial Clustering of
Applications with Noise

带噪声的 基于密度的 空间聚类方法

一种让“类自然生长”的算法


DBSCAN 的三种点

- 能够“向外扩展”的点：核心点（core point）
- 被扩展纳入但不能继续扩展的点：边界点（border point）
- 无法归入任何类的点：噪声（noise）


DBSCAN 的三种点

- 能够“向外扩展”的点：核心点（core point）
- 被扩展纳入但不能继续扩展的点：边界点（border point）
- 无法归入任何类的点：噪声（noise）

例如 $\text{MinPts}=4$ ：



DBSCAN 解决双月牙聚类




密度聚类的思想

- 聚类不一定来自中心结构
- 也不一定来自层次结构
- 结构可以从密度中自然生长

新的问题

如果结构在当前空间中不可见呢？


例如：



新的问题

如果结构在当前空间中不可见呢？

例如：



在当前空间中，这两个类无法分开


一种新思路

也许我们应该改变空间

一种新思路

也许我们应该改变空间

引入特征映射 ϕ ，把数据映射到新的特征空间



一种新思路

我们在新的特征空间完成聚类
再通过映射关系
将原空间的数据打上类别标签

特征映射 ϕ

我们刚才做了一件很“反常识”的事：改变数据所在的空间

但是，映射 ϕ 从哪里来？

特征映射 ϕ

我们刚才做了一件很“反常识”的事：改变数据所在的空间

但是，映射 ϕ 从哪里来？

- 可以来自人为设计的特征
- 可以来自核方法（Kernel）
- 可以来自神经网络的表示学习

特征映射 ϕ

我们刚才做了一件很“反常识”的事：改变数据所在的空间



但是，映射 ϕ 从哪里来？

- 可以来自人为设计的特征
- 可以来自核方法（Kernel）
- 可以来自神经网络的表示学习


我们暂时不详细解释这个问题，但请记住：

好的表示，比好的算法更重要

双月牙的空间变换（映射来自核方法）



特征空间上的聚类结果



一个更深刻的视角

当结构在当前空间中难以显现时

我们可以改变数据的表示方式

让结构变得可见

不同的“世界观”

同一份数据，在不同的视角下
会呈现出完全不同的结构

- 中心方法：数据围绕“代表点”
- 层次方法：数据形成“嵌套结构”
- 密度方法：数据在“局部聚集”
- 特征映射方法：结构存在于“另一个特征空间”

不同的“世界观”

同一份数据，在不同的视角下
会呈现出完全不同的结构

- 中心方法：数据围绕“代表点”
- 层次方法：数据形成“嵌套结构”
- 密度方法：数据在“局部聚集”
- 特征映射方法：结构存在于“另一个特征空间”

没有唯一正确的结构, 只有合适的观察方式

课程小结

我们从一个简单的问题出发，一步步走到了这里

- 从“放置基站”到 K-means
- 从配送问题到 K-medians
- 从 k 的困惑到层次结构
- 从非凸结构到密度聚类
- 从不可分到特征空间

课程小结

我们从一个简单的问题出发，一步步走到了这里

- 从“放置基站”到 K-means
- 从配送问题到 K-medians
- 从 k 的困惑到层次结构
- 从非凸结构到密度聚类
- 从不可分到特征空间

我们真正学到的不是算法，而是如何建模世界

数据中可能蕴含规律
但它并不会自动呈现为“结构”
所谓的“结构”
来自于数据与建模假设的相互作用
而算法
只是这种作用的计算方式