



唐山学院
TANGSHAN UNIVERSITY

课程设计（报告）

利用 Ia 型超新星数据估计哈勃常数

姓名学号：李芷欣 4234014000

许 彤 4234014333

王 浩 4234014666

赵博文 4234014999

专 业：数据科学与大数据技术

学 院：人工智能学院

课程名称：商务智能方法与应用

任课教师：刘颂 孟庆鑫 郭嘉伟

2026 年 4 月 12 日

作者分工

李芷欣: 问题定义与业务价值分析; 数据处理流程设计; 结果解读

许 彤: 数据清洗、特征工程与可视化实现

王 浩: 软件环境搭建、代码实现与调试优化

赵博文: 研究框架梳理、理论校验、论文撰写与修改

大语言模型使用说明

使用程度:

- ☐ 0 级: 仅使用拼写检查与基础文献检索
- ☐ I 级: 包含语言润色、代码辅助调试、文献整理、论文排版等, 对结果有辅助作用
- ☒ II 级: 介入了推理过程、实验设计、数据处理、代码生成、结论的推导或大段内容的草拟, 对成果有实质性贡献, 但最终核心观点由学生认同并承担责任

使用工具:

ChatGPT (基于 GPT-5.3), DeepSeek-v3, 豆包

使用说明:

本报告在以下环节使用了 LLM:

- 使用 ChatGPT 生成数据读取、距离转换、速度计算及线性回归建模的 Python 代码;
- 使用 ChatGP、DeepSeek、豆包辅助撰写报告部分段落及语句润色。

所有 LLM 生成内容均经过作者人工校验、修改与最终确认。作者独立完成了核心问题定义、数据转换逻辑验证、模型结果分析与业务结论, 对报告的全部学术内容负责。

利用 Ia 型超新星数据估计哈勃常数

李芷欣

许 彤

王 浩

赵博文

4234014000

4234014333

4234014666

4234014999

摘 要

本报告以 Kaggle 上的模拟数据集“Hubble Law Astronomy Lab”为对象，完整展示了从原始观测到参数估计的分析流程。我们将 Ia 型超新星的峰值视星等转换为光度距离，将宿主星系红移转换为退行速度，并采用过原点的普通最小二乘法拟合哈勃定律 $v = H_0 d$ ，得到哈勃常数估计值 $\hat{H}_0 = 75.23 \text{ km} \cdot \text{s}^{-1} \cdot \text{Mpc}^{-1}$ 。结果与局域距离梯方法得到的测量值较为接近，而与基于宇宙微波背景、在 Λ CDM 框架下推断的 Planck 值存在差异。报告进一步分析了该差异的来源、样本规模与模型假设带来的不确定性，并总结了一个可迁移的数据驱动参数辨识范式。

1 问题背景与需求

20 世纪 20 年代，天文学家埃德温·哈勃通过观测遥远星系，发现了星系退行速度与其距离之间的线性关系

$$v = H_0 \cdot d,$$

其中 v 为星系退行速度， d 为距离，比例常数 H_0 被称为哈勃常数。这一发现即哈勃定律，它奠定了现代宇宙学的观测基础，首次提供了宇宙正在膨胀的直接证据。经典综述指出，哈勃常数的估计不仅决定了当代宇宙的膨胀尺度，也一直是系统误差与方法差异最集中的问题之一^[1]。近年来，Planck 基于早期宇宙并在 Λ CDM 框架下推断得到 $H_0 = 67.4 \pm 0.5$ ，而 SH0ES 局域距离梯测量得到 $H_0 = 73.04 \pm 1.04$ ，二者之间存在持续的“哈勃张力”^[2-4]。

哈勃常数的估计问题本质上是从带噪声的观测数据中识别一个具有明确物理含义的系统参数 H_0 。本项目以哈勃常数估计为载体，旨在完整展示一套可泛化的“从原始数据到参数估计”的分析流程。

1.1 核心问题定义

给定一个包含 Ia 型超新星观测数据的 CSV 文件，其中每条记录包含两个字段：

- `apparent_magnitude`: 峰值视星等 m ;
- `redshift`: 宿主星系红移 z 。

我们的目标是完成以下四步:

- 1 利用距离模数公式将视星等 m 转换为光度距离 d (单位: Mpc);
- 2 利用低红移近似 $v \approx cz$ 将红移 z 转换为退行速度 v (单位: km/s);
- 3 基于转换后的 (d_i, v_i) 数据点, 通过线性回归拟合哈勃定律 $v = H_0 d$, 估计哈勃常数 H_0 ;
- 4 对估计结果、误差来源和业务/科学含义进行解释。

2 数据说明与预处理

本报告所使用的数据集为 Kaggle 平台上的 Hubble Law Astronomy Lab^[5], 作者为 Austin Hinkel。该数据集是用于天文学教学的模拟数据, 包含 400 个 Ia 型超新星的峰值视星等及其宿主星系的红移值。

2.1 特征转换与构造

原始数据不能直接用于拟合哈勃定律, 需要经过两步特征工程处理:

2.1.1 距离计算: 从视星等到光度距离

天文学中, 天体的绝对星等 M 定义为将其放置在 10 秒差距 (pc) 标准距离处所呈现的视星等。对于 Ia 型超新星, 其峰值绝对星等具有高度一致性, 约为 $M \approx -19.3$ 。视星等 m 与光度距离 d (单位: pc) 之间通过距离模数公式关联:

$$m - M = 5 \log_{10}(d) - 5.$$

由此解出距离 d (单位: pc):

$$d = 10^{(m-M+5)/5}.$$

随后, 我们将距离单位从秒差距 (pc) 转换为天文研究中常用的百万秒差距 (Mpc), 换算关系为 $1 \text{ Mpc} = 10^6 \text{ pc}$ 。

2.1.2 速度计算: 从红移到退行速度

在低红移 ($z \ll 1$) 近似下, 星系的退行速度 v 与红移 z 满足 $v \approx cz$, 其中 $c = 2.99792458 \times 10^5 \text{ km/s}$ 为光速^[1]。本数据集的红移值均小于 0.1, 满足低红移条件, 故

采用此近似公式进行速度转换。

2.1.3 字段说明

表 1 展示了原始字段与派生字段说明。

表 1: 原始字段与派生字段说明

字段	含义	处理方式
<code>apparent_magnitude</code>	峰值视星等 m	原始输入, 作为距离模数公式的左端量
<code>redshift</code>	红移 z	原始输入, 作为速度近似公式的输入
<code>d_pc</code>	光度距离 (pc)	由 m 通过距离模数计算得到
<code>d_mpc</code>	光度距离 (Mpc)	将 pc 转换为 Mpc 后得到
<code>v_kms</code>	退行速度 (km/s)	由 z 与光速近似换算得到

2.2 数据清洗与探索性分析

完成特征转换后, 我们对数据集进行了基本检查: 所有 400 条记录均无缺失值, 视星等和红移值的量级合理。我们绘制了转换后的距离—速度散点图 (见图 1), 初步观察显示距离与速度之间存在明显的正相关趋势, 与哈勃定律的预期一致。




图 1: 转换后的距离—速度散点图

3 方案设计与方法选择

本报告采用过原点的普通最小二乘法（OLS）拟合哈勃定律：

$$v_i = H_0 d_i + \varepsilon_i.$$

选择该模型基于以下理由：

- 理论一致性：哈勃定律本身是线性关系，线性回归是理论上最自然的选择；
- 高可解释性：回归系数直接对应哈勃常数 H_0 ，具有明确的物理含义；
- 统计无偏性：OLS 估计量是无偏的，这对物理参数估计至关重要。

3.1 OLS 估计的无偏性推导

线性回归模型矩阵形式： $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ ，其中 $\boldsymbol{\varepsilon}$ 为误差项，满足 $\mathbb{E}(\boldsymbol{\varepsilon}) = \mathbf{0}$ 。OLS 估计量：

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}.$$

代入 $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ 得：

$$\hat{\boldsymbol{\beta}} = \boldsymbol{\beta} + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \boldsymbol{\varepsilon}.$$

取期望，由 $\mathbb{E}(\boldsymbol{\varepsilon}) = \mathbf{0}$ 得：

$$\mathbb{E}(\hat{\boldsymbol{\beta}}) = \boldsymbol{\beta}.$$

因此，OLS 估计量是 $\boldsymbol{\beta}$ 的无偏估计，确保了参数估计的系统性准确性。

3.2 为什么不使用正则化？

虽然岭回归（Ridge）或 Lasso 等正则化方法能够通过引入惩罚项降低模型方差、缓解过拟合，但这些方法会引入估计偏差：

$$\hat{\boldsymbol{\beta}}_{\text{ridge}} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}, \quad \mathbb{E}(\hat{\boldsymbol{\beta}}_{\text{ridge}}) \neq \boldsymbol{\beta} \text{ (当 } \lambda > 0 \text{)}.$$

在物理参数辨识任务中，引入偏差会导致对参数的系统性误估，其代价远大于降低方差带来的预测稳定性收益。因此，本报告坚持使用无偏的 OLS 方法。

4 核心实现

核心代码分为三部分：

- 1 从 Kaggle 下载数据，并读取 CSV 文件；
- 2 构造距离、速度字段，并用过原点最小二乘法求出 H_0 ；
- 3 绘制散点图与拟合直线。

4.1 核心代码片段

本报告的分析基于 Python 3.13, 主要依赖以下科学计算库: pandas (数据处理)、numpy (数值计算)、matplotlib (可视化)。核心代码实现如下:

代码 1: 哈勃常数估计的核心逻辑

```

1 M = -19.3          # Ia型超新星的绝对星等
2 c_kms = 299792.458 # 光速 (km/s)
3
4 # 清洗与计算
5 df = df.dropna(subset=['apparent_magnitude', 'redshift']).copy()
6 df['d_pc'] = 10 ** ((df['apparent_magnitude'] - M + 5) / 5.0)
7 df['d_mpc'] = df['d_pc'] / 1e6
8 df['v_kms'] = c_kms * df['redshift']
9
10 # 选择数据集用于拟合
11 X = df['d_mpc'].values
12 y = df['v_kms'].values
13
14 # 过原点的最小二乘解
15 H0_origin = np.sum(X * y) / np.sum(X * X)

```

4.2 模型训练结果

运行上述代码，我们得到如下回归结果：

$$\text{哈勃常数估计值 } \hat{H}_0 = 75.23 \text{ km/s/Mpc.}$$

拟合直线与原始数据点的关系如图 2 所示。

5 结果分析与解读

按照上述流程，得到哈勃常数估计值 $\hat{H}_0 = 75.23 \text{ km s}^{-1} \text{ Mpc}^{-1}$ 。从数值上看，该结果高于 Planck 基于早期宇宙并在 Λ CDM 框架下推断的值，但与 SH0ES 距离梯测量的局域结果较为接近^[2-4]。

我们需要指出，本报告结果的误差主要来自三类因素：




图 2: 线性回归拟合结果

表 2: 本报告结果与常见权威测量的对比

来源	结果	说明
本报告（模拟数据回归）	75.23	由 Ia 型超新星模拟数据经 OLS 估计得到
SH0ES（局域距离梯）	73.04 ± 1.04	通过几何锚点、造父变星与 SN Ia 标定得到
Planck 2018 (Λ CDM)	67.4 ± 0.5	由宇宙微波背景并在标准宇宙学模型下推断得到

- 绝对星等设定误差：本报告采用固定的 $M = -19.3$ ，这本身就是标准化近似；
- 低红移近似误差： $v \approx cz$ 并非严格精确；
- 模拟数据特性：这是模拟数据，不等同于真实巡天观测。

Riess 与 Breuval 的综述指出，局域距离梯的关键在于尽量用差分测量压低系统误差，并通过多个锚点交叉校验^[4]。因此，当我们看到一个与 SH0ES 更接近的结果时，我们认为合理的解释应是“数据与方法口径一致”。

6 结论

本报告基于 Ia 型超新星教学数据，完成了从原始观测量到哈勃常数估计的完整流程。通过距离模数公式和低红移速度近似进行特征工程，再用过原点 OLS 拟合哈勃定律，得到 $\hat{H}_0 = 75.23 \text{ km s}^{-1} \text{ Mpc}^{-1}$ 。这一结果与局域距离梯测量更为接近，也说明了在参数辨识任务中，数据转换与方法假设的影响往往比模型本身更关键。

本报告构建的端到端参数辨识流程，不仅可迁移至天文观测设备校准、宇宙膨胀模型参数优化等天文工程决策场景，也可泛化应用于金融风控参数估计、工业传感器标定等通用数据驱动参数辨识任务。

参考文献

- [1] FREEDMAN W L, MADORE B F. The hubble constant[J/OL]. Annual Review of Astronomy and Astrophysics, 2010, 48: 673-710. DOI: 10.1146/annurev-astro-082708-101829.
- [2] Planck Collaboration, AGHANIM N, et al. Planck 2018 results. VI. cosmological parameters[J/OL]. Astronomy & Astrophysics, 2020, 641: A6. DOI: 10.1051/0004-6361/201833910.
- [3] RIESS A G, YUAN W, MACRI L M, et al. A comprehensive measurement of the local value of the hubble constant with 1 km/s/Mpc uncertainty from the hubble space telescope and the SH0ES team[J/OL]. The Astrophysical Journal Letters, 2022, 934 (1): L7. DOI: 10.3847/2041-8213/ac5c5b.
- [4] RIESS A G, BREUVAL L. The local value of H_0 [A/OL]. arXiv (2024). <https://arxiv.org/abs/2308.10954>.
- [5] HINKEL A. Hubble law astronomy lab[EB/OL]. 2024. <https://www.kaggle.com/datasets/austinhinkel/hubble-law-astronomy-lab>.

A 实验完整代码

代码 2: 验证哈勃定律的 Python 代码

```

1 import numpy as np
2 import pandas as pd
3 import matplotlib.pyplot as plt
4 import kagglehub
5 import os
6
7 def process_hubble_data(df):
8     """
9     清洗数据并计算哈勃常数 (H0)
10    物理常量 M 和 c_kms 已内置在此函数中
11    """
12    M = -19.3          # Ia型超新星的绝对星等
13    c_kms = 299792.458 # 光速 (km/s)
14
15    # 清洗与计算
16    df = df.dropna(subset=['apparent_magnitude', 'redshift'])
17    df['d_pc'] = 10 ** ((df['apparent_magnitude'] - M + 5) / 5.0)
18    df['d_mpc'] = df['d_pc'] / 1e6
19    df['v_kms'] = c_kms * df['redshift']
20
21    # 选择数据集用于拟合
22    X = df['d_mpc'].values
23    y = df['v_kms'].values
24
25    # 过原点的最小二乘解
26    H0_origin = np.sum(X * y) / np.sum(X * X)
27
28    return df, H0_origin
29
30 def plot_hubble_law(df, H0):
31     """
32     绘制哈勃定律拟合图
33     """
34    X = df['d_mpc'].values
35    y = df['v_kms'].values
36
37    plt.figure(figsize=(8, 5))
38    plt.margins(0)

```

```

39 plt.scatter(X, y, label='Data points')
40
41 # 绘制拟合线
42 x_line = np.linspace(0, X.max() * 1.05, 100)
43 plt.plot(x_line, H0 * x_line, 'r-', label=f'Fit: H0 = {H0:.2f} km/s/Mpc')
44
45 plt.xlabel('Distance (Mpc)')
46 plt.ylabel('Recession velocity (km/s)')
47 plt.title('Hubble Law Fit from Type Ia Supernovae')
48 plt.legend()
49 plt.tight_layout()
50 plt.grid(True)
51 plt.show()
52
53 # ===== 主程序流程 =====
54 if __name__ == "__main__":
55     # 1. 下载数据
56     path = kagglehub.dataset_download("austinhinkel/hubble-law-astronomy-lab")
57
58     # 2. 读取数据
59     files_in_folder = os.listdir(path)
60     csv_file = [f for f in files_in_folder if f.endswith('.csv')]
61
62     if csv_file:
63         csv_path = os.path.join(path, csv_file[0])
64         df = pd.read_csv(csv_path)
65
66         # 3. 检查数据
67         print("\nData reading successful! First 5 lines:\n")
68         print(df.head())
69         input("\nPress [Enter] to continue...")
70
71         # 4. 计算
72         df_processed, H0 = process_hubble_data(df)
73         print(f"\nCalculated H0 = {H0:.2f} km/s/Mpc")
74
75         # 5. 绘图
76         plot_hubble_law(df_processed, H0)
77     else:
78         raise FileNotFoundError("CSV file not found!")

```