

概率建模

Probabilistic Modeling

孟庆鑫

人工智能学院



唐山学院
TANGSHAN UNIVERSITY

课件获取地址



GitHub



Gitee

1. 信息量与信息熵

2. 最大熵原理

3. 概率建模

信息量的直觉

假设你收到如下三条消息：

- 明天最高气温超过 10°C，湿度低于 40%
- 未来一周内，太阳都会从东方升起
- 一颗直径 10 公里的小行星将在三天后撞击地球

虽然这三条都是“消息”，但它们带来的冲击完全不同：

事件概率	接近 1	中等概率	极小概率
信息量	几乎没有信息	一定信息	包含巨量信息

因此：信息量应该由事件的概率决定，即

$$I = I(p)$$

观察 1：概率与信息量的关系

直觉上：

- 信息量非负，且概率越小信息量越大，即

$$I(p) \geq 0 \quad \text{且} \quad p_1 < p_2 \implies I(p_1) > I(p_2)$$

- 信息量 $I(p)$ 是连续函数，它不因概率 p 的微小改变而发生跳变
- 必然发生的事件几乎不会带来新的信息，即

$$p \rightarrow 1 \implies I(p) \rightarrow 0$$

- 几乎不可能发生的事件一旦发生，将带来巨大信息

$$p \rightarrow 0 \implies I(p) \rightarrow +\infty$$

观察 2：独立事件的信息可加性

- 相互独立的事件 A 和 B 同时发生，即 $P\{A \cap B\} = P\{A\} \cdot P\{B\}$
- 将 $A \cap B$ 视为一个整体，信息量为 $I(P\{A \cap B\})$
- 将 A 和 B 视为两个独立事件，总信息量为 $I(P\{A\}) + I(P\{B\})$

因此，信息量满足如下关系：

$$I(P\{A\} \cdot P\{B\}) = I(P\{A\}) + I(P\{B\})$$

我们可以将其简化为：

$$I(pq) = I(p) + I(q)$$

信息量的表达式

我们需要一个函数 I 使得：

$$I(pq) = I(p) + I(q)$$

唯一满足这一性质的非负连续函数是：

$$I(p) = -\log p, \quad p \in (0, 1]$$

其中我们设定 $\log$ 表示任意的底大于 1 的对数

通常约定由 $I(p) = -\log_2 p$ 度量的信息量单位为比特 (bit)

感兴趣的同学可尝试借助 AI 工具证明 $I(p)$ 的表达式

随机变量的信息量

设随机变量 X 的分布为 P

事件 $X = x$ 的信息量:

$$I(P(x)) = -\log P(x)$$

平均信息量：熵

我们关心随机变量 X 平均提供多少信息： $H(X) = \mathbb{E}[I(X)]$ ，即

定义：随机变量的熵 (Entropy)

$$H(X) = - \sum_x P(x) \log P(x)$$

平均信息量：熵

我们关心随机变量 X 平均提供多少信息： $H(X) = \mathbb{E}[I(X)]$ ，即

定义：随机变量的熵 (Entropy)

$$H(X) = - \sum_x P(x) \log P(x)$$

- 熵由 Claude Shannon 在 1948 年引入。据 Shannon 本人回忆，他曾就如何命名自己的不确定性函数请教数学家 Von Neumann。Von Neumann 建议：“叫它熵吧，有两个原因：第一，不确定性函数在统计力学中已经有这个名字；第二，更重要的是，没有人真正知道熵是什么，这样在任何辩论中你都能占优势。”

——1971 年《科学美国人》

- 这段轶事虽然无法严格考证，但它反映了命名中的微妙考量——好的命名往往能让新概念更容易被传播

从概率均衡化实验观察熵的变化

考虑分布

$X:$	x_1	x_2	$\cdots$	x_n
$P:$	p_1	p_2	$\cdots$	p_n

假设分布是不均匀的，即存在

$$p_i > p_j$$

我们从较大的概率 p_i 中取出一小部分 ε ，转移给较小的概率 p_j ：

$$p'_i = p_i - \varepsilon, \quad p'_j = p_j + \varepsilon$$

其余概率保持不变。我们观察熵的改变

熵的变化

为便于计算，熵中的对数取自然对数，并令 $f(p) = -p \ln p$
变化前的熵为

$$\begin{aligned} H &= -p_i \ln p_i - p_j \ln p_j - \sum_{k \neq i, j} p_k \ln p_k \\ &= f(p_i) + f(p_j) + \sum_{k \neq i, j} f(p_k) \end{aligned}$$


变化后的熵为

$$\begin{aligned} H' &= -p'_i \ln p'_i - p'_j \ln p'_j - \sum_{k \neq i, j} p_k \ln p_k \\ &= f(p'_i) + f(p'_j) + \sum_{k \neq i, j} f(p_k) \end{aligned}$$

我们只需要关注 $f(p_i) + f(p_j)$ 与 $f(p'_i) + f(p'_j)$ 的大小关系

关键观察

注意到 $f''(p) = -1/p < 0$ ，即 f 是个凹函数，其图像如下：



观察可知： $f(p_i) + f(p_j) < f(p'_i) + f(p'_j)$ ，这意味着 $H < H'$ ，即

概率均衡化使熵增加

结论

- 只要概率不完全相等，就可以通过“概率均衡化”使熵增加
- 不断重复这一过程，最终得到均匀分布

$$p_1 = p_2 = \cdots = p_n = \frac{1}{n}$$

此时熵达到最大

- 熵度量了分布的均衡程度

1. 信息量与信息熵

2. 最大熵原理

3. 概率建模

最大熵的意义

当我们对随机变量 X 的真实分布一无所知时，
自然的做法是为每一种可能取值赋予相同的概率。
因为在缺乏任何额外信息的情况下，
我们没有理由认为某一种取值比其他取值更可能发生

换句话说，在所有可能的概率分布中，
我们倾向于选择**最不偏向任何特定结果**的分布，
也即，我们在选择**使熵最大化的分布**

统计约束

在实际问题中，我们可能会知道一些统计信息，它们构成约束：

$$\mathbb{E}[f_k(X)] = c_k, \quad k = 1, 2, \dots, K$$

例如在关联分析中，令随机变量 X 为一笔交易，并设

$$f_A(x) = \begin{cases} 1 & A \subseteq x \\ 0 & \text{otherwise} \end{cases}$$

则商品 A 的出现概率 $\hat{P}(A) = \text{support}(A) = 0.7$ 等价于

$$\mathbb{E}[f_A(X)] = \frac{1}{N} \sum_{i=1}^N f_A(x_i) = 0.7$$

有统计约束时，我们如何选择分布？

当我们对随机变量 X 的真实分布不再一无所知时，
自然的做法是：
在满足这些约束的条件下，
不再引入任何额外的信息，
确保分布最不偏向任何特定结果，即

最大熵原理

在所有满足已知约束的概率分布中，选择使熵最大的分布，避免引入不必要的偏见

1. 信息量与信息熵
2. 最大熵原理
3. 概率建模

最大熵问题的形式化

$$\arg \max_P - \sum_x P(x) \ln P(x)$$

$$\text{s.t. } \sum_x P(x) = 1$$

归一化条件

$$\sum_x P(x) f_k(x) = c_k, \quad k = 1, \dots, K$$

统计约束

用 Lagrange 乘子法求解最大熵问题

构造 Lagrange 函数（乘子 λ_0 对应归一化， λ_k 对应第 k 个约束）：

$$\mathcal{L}(P, \lambda) = - \sum_x P(x) \ln P(x) - \lambda_0 \sum_x P(x) - \sum_{k=1}^K \lambda_k \sum_x P(x) f_k(x)$$

对每个 $P(x)$ 求偏导并令其为 0：

$$\frac{\partial \mathcal{L}}{\partial P(x)} = -(\ln P(x) + 1) - \lambda_0 - \sum_{k=1}^K \lambda_k f_k(x) = 0.$$

解得

$$P(x) = \frac{1}{Z(\lambda)} \exp \left(\sum_{k=1}^K \lambda_k f_k(x) \right)$$

其中归一化常数 $Z(\lambda) = \exp(1 + \lambda_0) = \sum_x \exp \left(\sum_k \lambda_k f_k(x) \right)$

结论

在给定一组特征期望约束下
熵最大化必然产生指数族分布

示例 1: 伯努利分布 / Logistic

- 令 $X \in \{0, 1\}$, 已知 $\mathbb{E}[X] = p$
- 取特征 $f_1(x) = x$, 最大熵解形式

$$P(x) = \frac{1}{Z} e^{\lambda x}, \quad x \in \{0, 1\}$$

- 写出具体概率:

$$P(1) = \frac{e^{\lambda}}{1 + e^{\lambda}} \quad P(0) = \frac{1}{1 + e^{\lambda}}$$

- 由期望约束 $P(1) = p$ 得到 $\lambda = \ln \frac{p}{1-p}$

示例 2：多项分布 / Softmax

X 取 n 个类别，已知每个类别的期望（或若干特征），最大熵给出：

$$P(x = i) = \frac{\exp(\sum_k \lambda_k f_k(i))}{\sum_j \exp(\sum_k \lambda_k f_k(j))}, \quad i = 1, \dots, n$$

示例 3：正态分布 / Gauss

若 $X \in \mathbb{R}$ ，已知一阶与二阶矩： $\mathbb{E}[X] = \mu$ ， $\mathbb{E}[X^2] = \nu$ ，最大熵给出：

$$p(x) = \frac{1}{Z} \exp(\lambda_1 x + \lambda_2 x^2)$$

这等价于高斯分布（只需整理指数项成二次多项式）

正态分布是均值与方差约束下的最大熵分布

课程小结

- 信息量：度量事件发生所带来的“惊讶程度”
- 信息熵：随机变量的平均信息量，度量分布的不确定性
- 熵的最大化性质：均匀分布熵最大；概率均衡化使熵增加
- 最大熵原理：在已知约束下，选择熵最大的分布
- 最大熵模型：在期望约束下，熵最大化的解为指数族分布
- 常见分布作为最大熵分布：
 - 伯努利分布（一阶矩） $\rightarrow$ Logistic 形式
 - 多项分布（类别期望） $\rightarrow$ Softmax 形式
 - 正态分布（一、二阶矩） $\rightarrow$ Gauss 形式